



ÉCOLE
SUPÉRIEURE
D'ÉLECTRICITÉ

Techniques de détection d'erreur avec phase d'apprentissage appliquées à la détection d'intrusion

Eric Totel
2014

- Apprentissage et vérification d'invariants
 - 1. Application centralisée**
 2. Application distribuée



- Projet ANR DALI (Design and Assessment of application Level Intrusion detection systems)
- Détection d'attaques contre les applications web
- Approche par invariants dynamiques
- Applications web (Insecure développée par Kereval)
- E-commerce, e-bank,...
- Langages interprétés (Ruby/Ruby on Rails)

- Nombreuses attaques contre les données
 - Injections SQL
 - Modification de données en requêtes
 - Modification de variables de session/cookies

```
1 class UsersController < ApplicationController
...
16 def login
17   if request.post?
18     # whole user is stored in the session
19     if session[:user] = User.authenticate(params[:user][:login], params[:user][:password])
20       flash[:notice] = 'You have been successfully logged in.'
21       if session[:user].admin
22         redirect_to :controller => '/admin/home', :action => 'index'
23       else
24         redirect_to :controller => '/user/home', :action => 'index'
25       end
26     else
27       flash.now[:error] = 'Login failed'
28     end
29   end
```

Ligne 21 :

```
21_session[:user].password == 17_params[:user][:password]
```

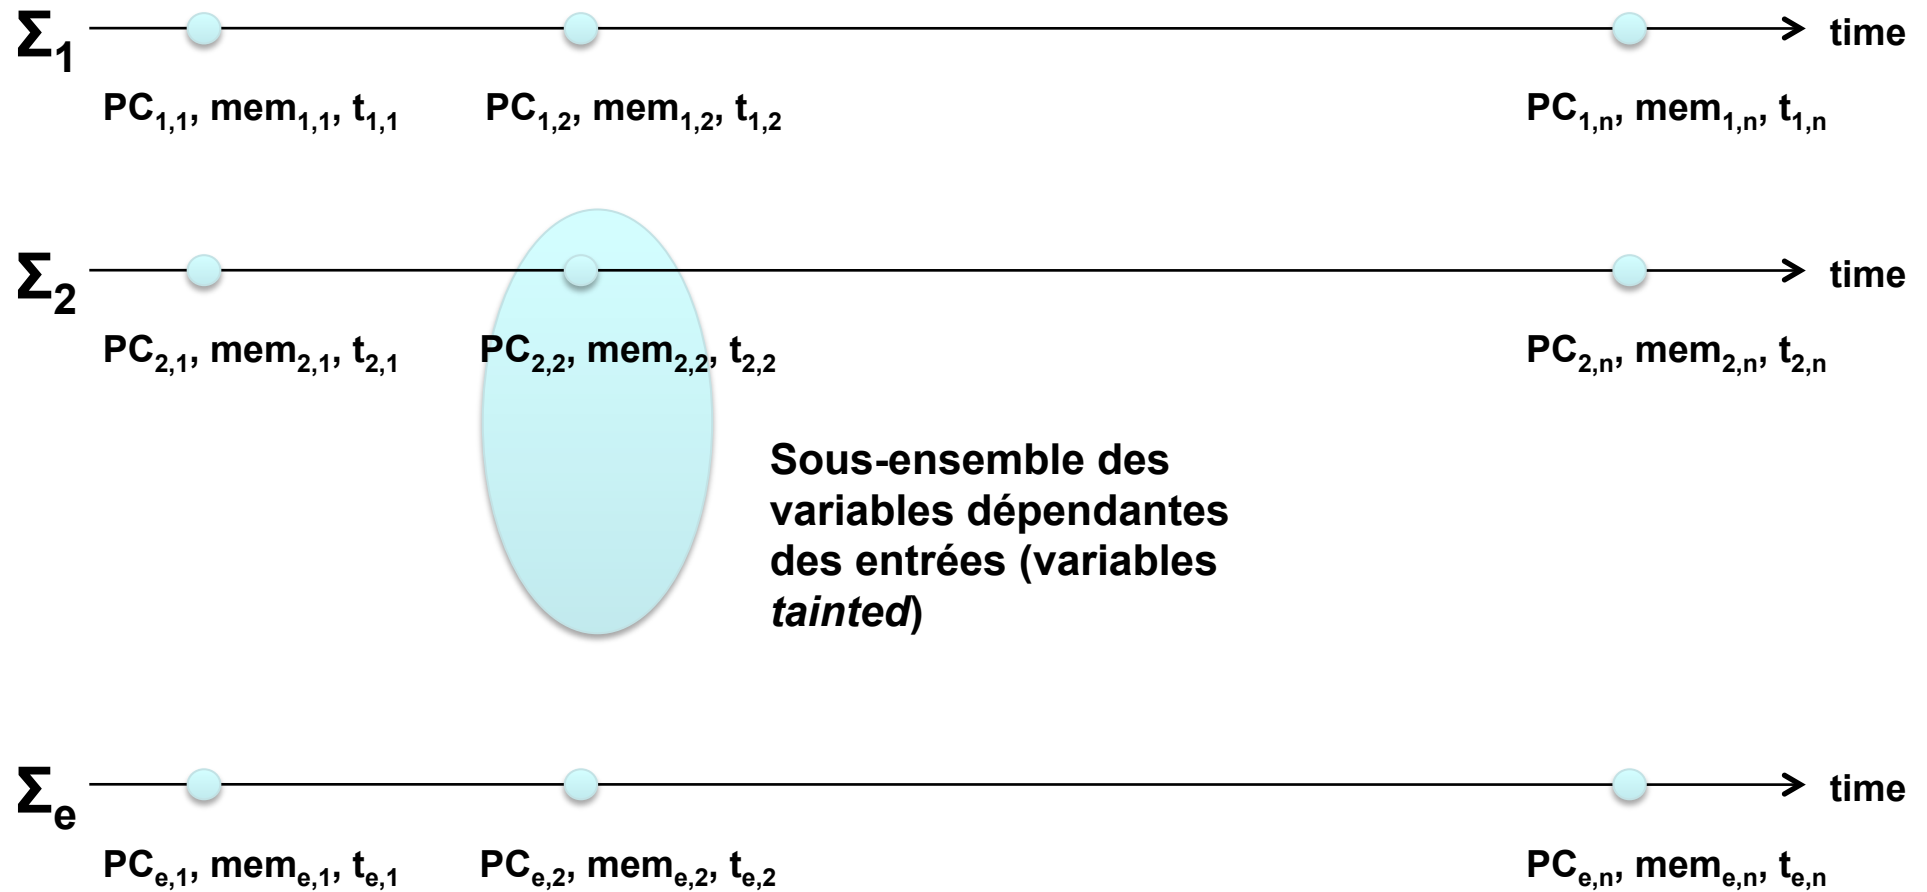
```
1 class UsersController < ApplicationController
...
16 def login
17   if request.post?
18     # whole user is stored in the session
19     if session[:user] = User.authenticate(params[:user][:login], params[:user][:password])
20       flash[:notice] = 'You have been successfully logged in.'
21       if session[:user].admin
22         redirect_to :controller => '/admin/home', :action => 'index'
23       else
24         redirect_to :controller => '/user/home', :action => 'index'
25       end
26     else
27       flash.now[:error] = 'Login failed'
28     end
29   end
```

Ligne 21 :

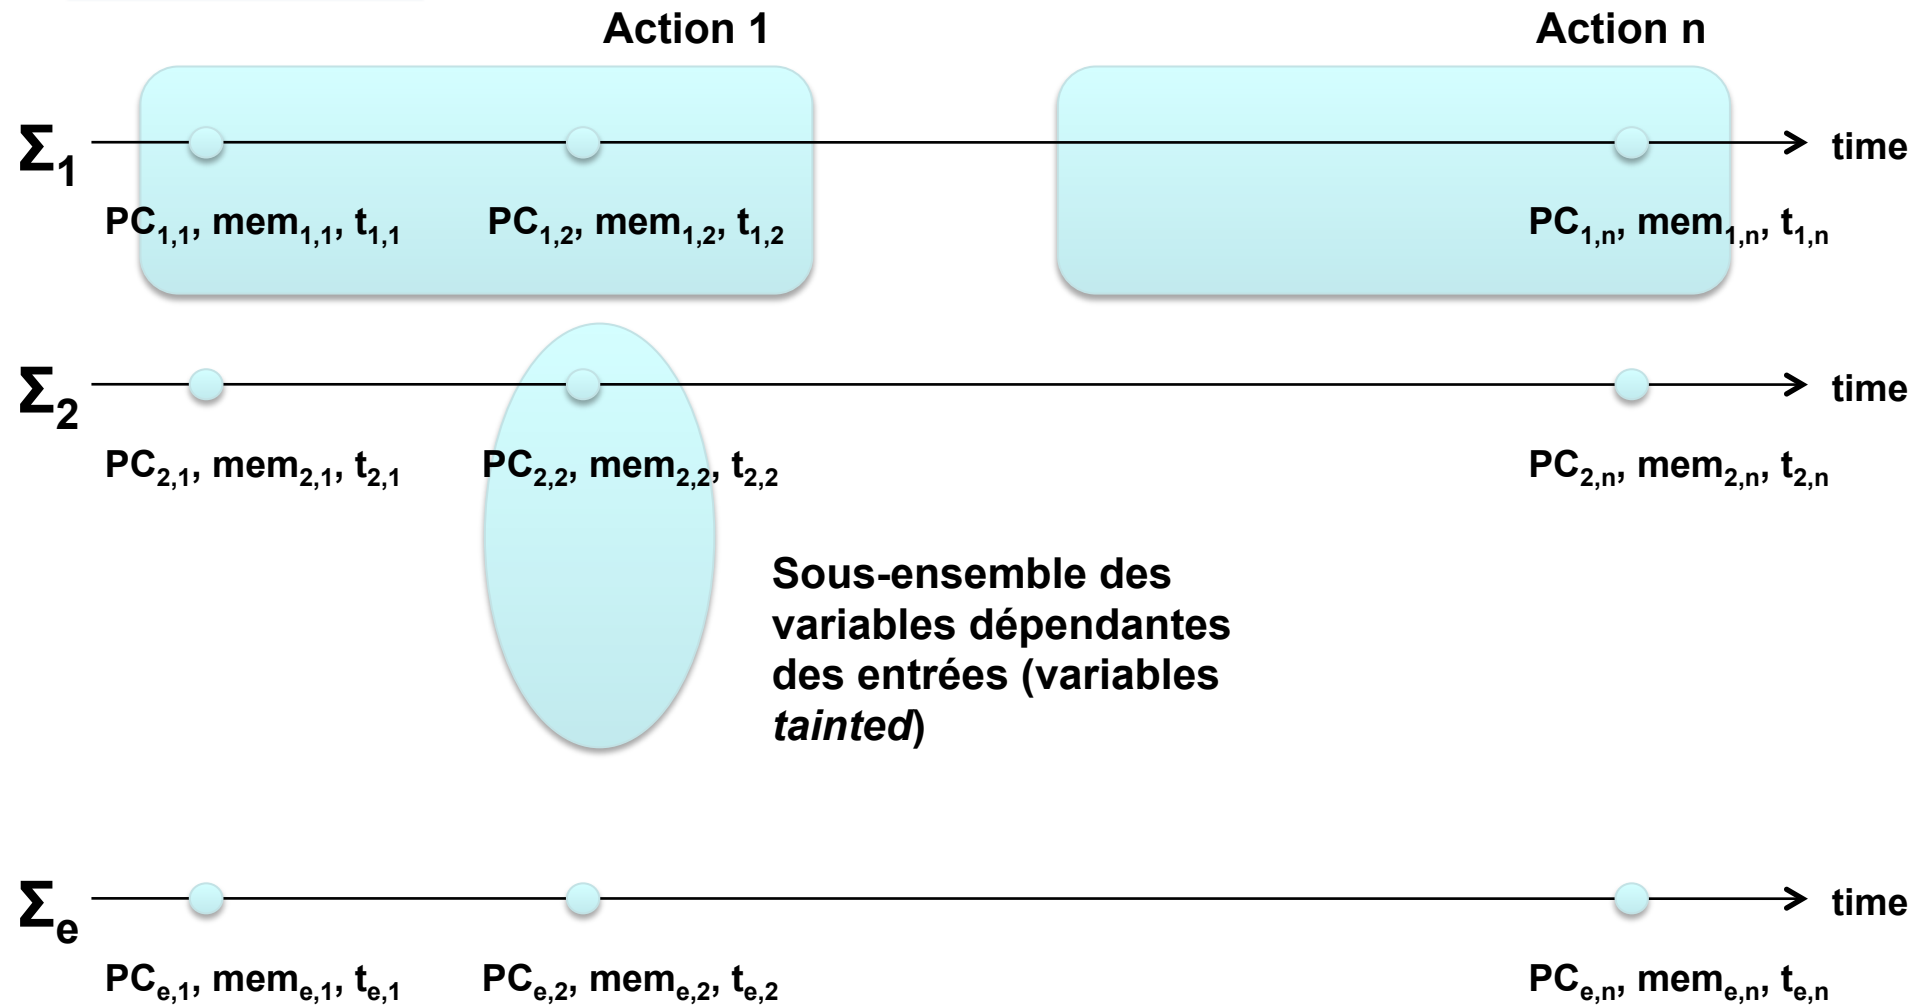
```
21_session[:user].password ≠ 17_params[:user][:password]
```

- Questions:
 - Sur quelles variables est-il intéressant de calculer des contraintes ?
 - Quelles contraintes chercher ?
 - Comment obtenir ces contraintes ?

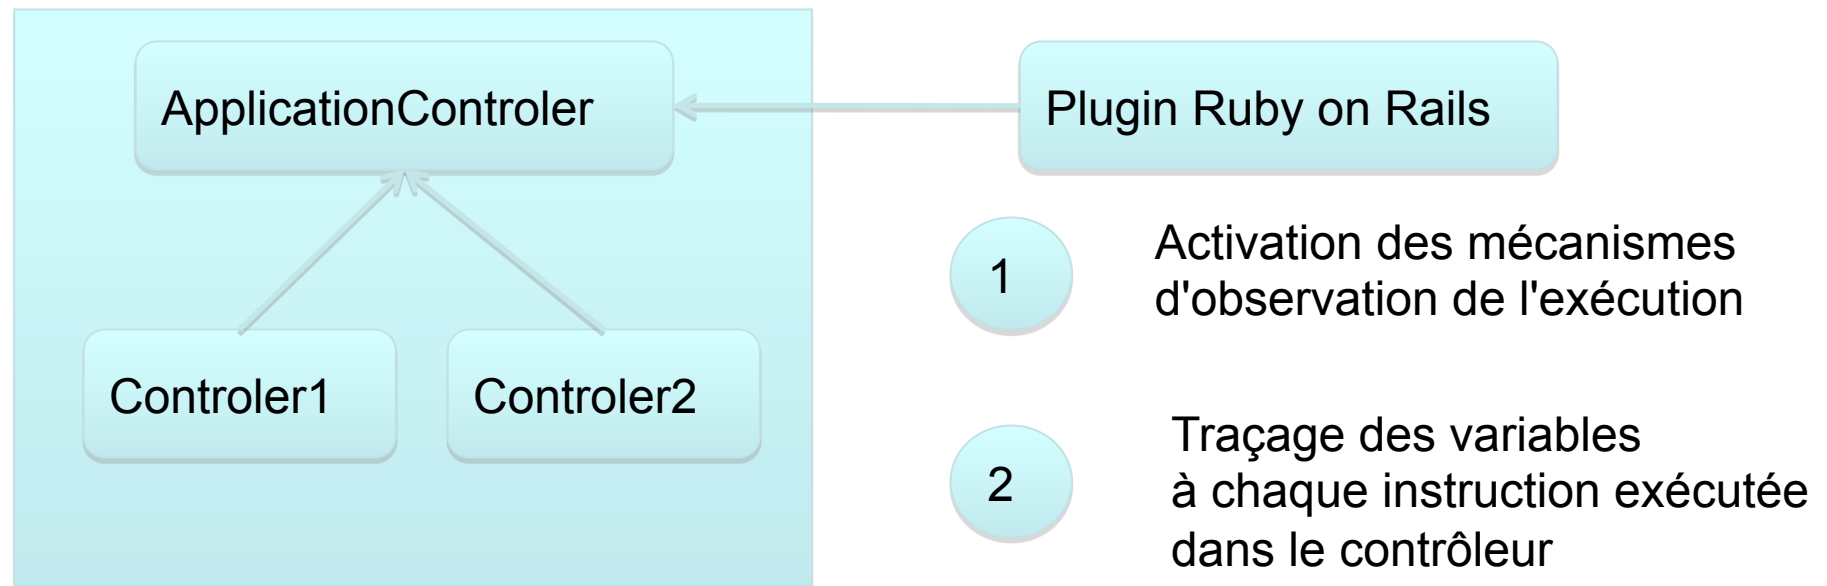
Ensemble de variables observées

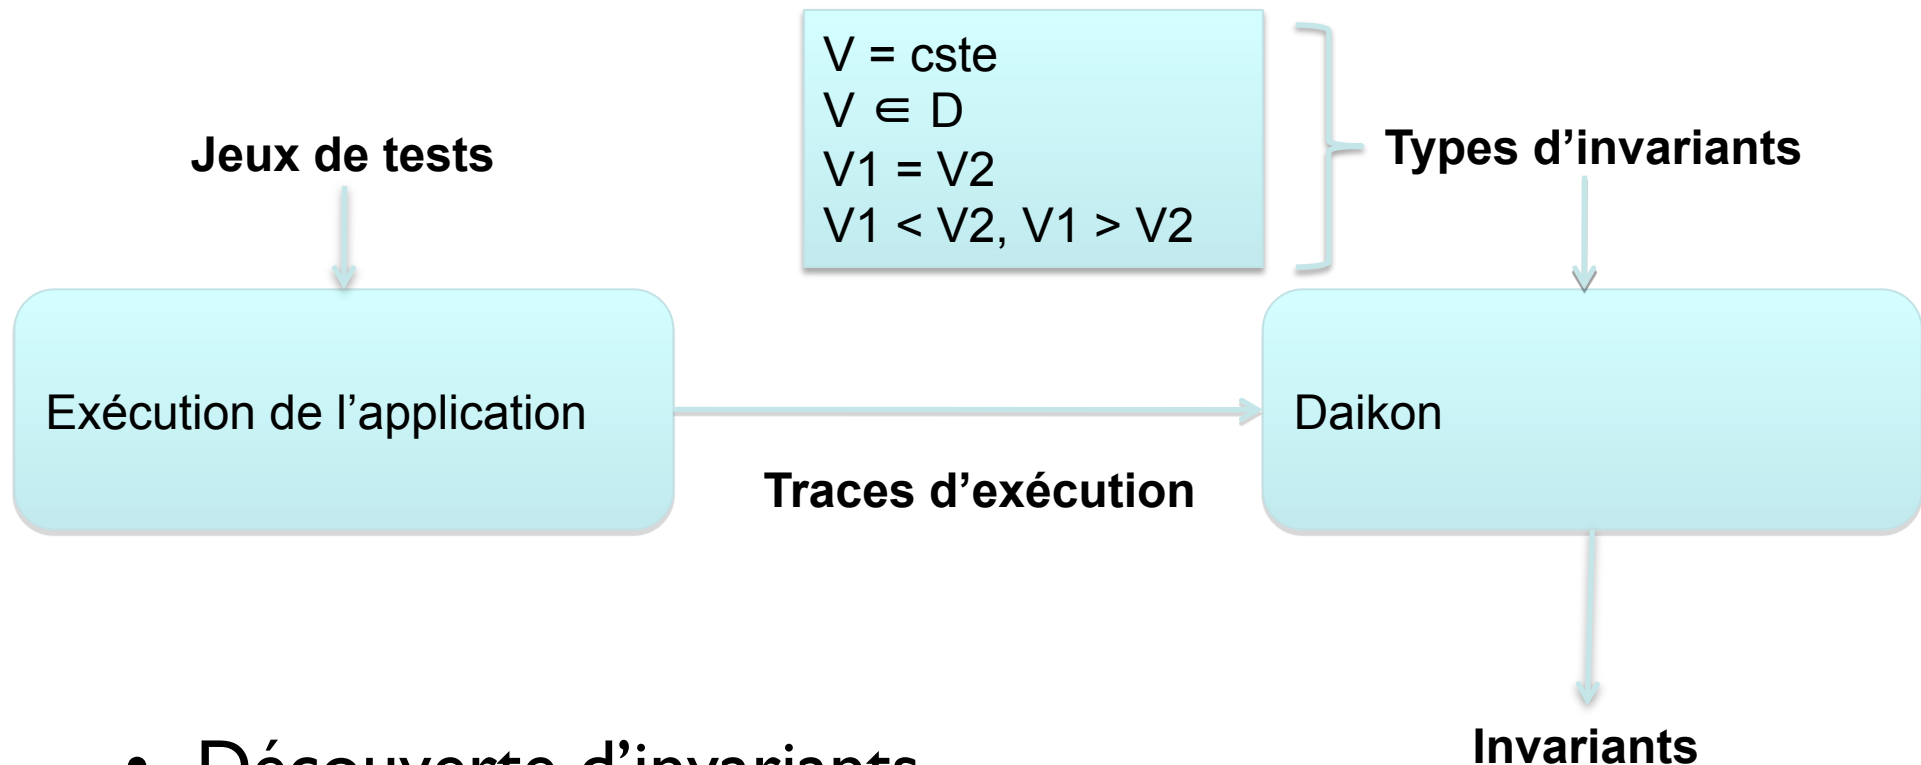


Ensemble de variables observées



- Framework de conception d'applications web
 - Modèle-Vue-Contrôleur
- Un contrôleur est composé d'actions
- Chaque requête utilisateur passe par une action
- Observation des variables critiques dans chaque action de chaque contrôleur





- Découverte d'invariants
 - Utilisation de Daikon (algo generate and check)
 - Découverte d'invariants dynamiques

- Phase d'apprentissage
- Utilisation d'un outil de test
- Selenium
 - Automatise le test d'applications WEB
 - Initialement prévu pour faire du test fonctionnel
 - Ici, utilisé pour réaliser l'apprentissage des invariants

Génération des invariants

Fichier de traces

```
1. ppt users.login:::POINT
2. ppt-type point
3. variable 17_p_user.password
4. var-kind variable
5. dec-type String
6. rep-type java.lang.String
7. variable 21_s_user.password
8. var-kind variable
9. dec-type String
10. rep-type java.lang.String
11.
12. users.login:::POINT
13. 17_p_user.password
14. "my_pass"
15. 21_s_user.password
16. "my_pass"
```

Daikon



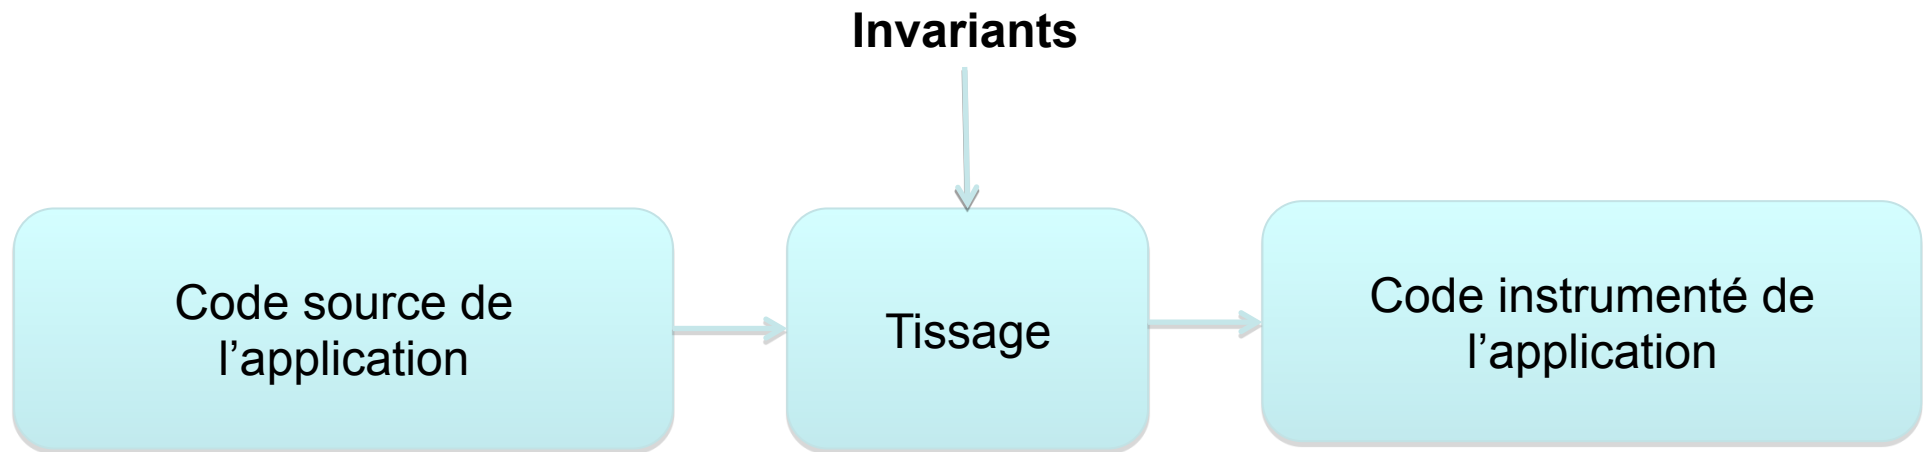
```
1. users.login:::POINT
2. 17_p_user.password == 21_s_user.password
```

Invariants

Compilateur
d'invariants



Invariants à tisser



Insecure	Lignes	Code instrumenté	Nombre d'invariants
Home_controller.rb	11	537	239
Products_controller.rb	26	1503	675
Reviews_controller.rb	37	1547	691
Users_controller.rb	51	1681	771

- Temps moyen d'exécution d'une page
 - Avant l'instrumentation: 16.5 ms
 - Après l'instrumentation: 125 ms (x8)

Trafic normal

Nombre de requêtes	Nombre d'alarmes	Nombre d'invariants violés
1623	20	4

Attaques automatisées

Nombre de requêtes générées	Nombre d'attaques réussies	Nombre d'alarmes générées	Faux positifs	Faux négatifs
13320	11	11	0	0

- Difficulté de la phase d'apprentissage
- Capacité de générer des invariants très complexes (configurable)
- Génère de très nombreux invariants (d'où l'excellente capacité de détection)
- Inconvénient: beaucoup d'invariants \Rightarrow perte de performance ...

- Apprentissage et vérification d'invariants
 1. Application centralisée
 - 2. Application distribuée**

1. Contexte général d'une application distribuée
2. Quelles attaques ?
3. Modélisation d'une application distribuée par apprentissage
 1. Traces locales et traces globales
 2. Inférence d'un automate à états finis
 3. Invariants temporels

- Un nombre défini de nœuds qui interagissent
- Horloges pas forcément bien synchronisées
- Ordre global des actions sur les nœuds difficile à obtenir
- Etat de l'art en détection d'intrusion
 - Hypothèse: horloges synchronisées
 - Corrélation centralisée d'alertes produites localement

- Confidentialité
 - Interception des messages (prévention par Cryptographie)
- Intégrité
 - Modification d'un message (prévention par crypto)
 - Rejouer un message
 - Destruction d'un message
 - Forger un message à destination d'un des processus de l'application distribuée, indépendamment de son contexte global

- Application distribuée
 - Logique globale
 - Chaque nœud responsable d'une partie de l'application
 - Problème de cohérence entre les nœuds
- Détection locale insuffisante pour détecter la compromission d'un nœud par rapport à l'état global

- Obtenues localement et constituées:
 - D'actions locales
 - Appels de fonctions/méthodes, appels systèmes
 - D'échanges de messages
 - Envoi de messages
 - Réception de messages
 - sur des canaux de communication entre les nœuds/
processus

Processus 1
(nœud 1)

a
c0
c1!m

Processus 2
(nœud 2)

d
c1?m
y

- Un canal de communication unidirectionnel c1 de P1 vers P2
- Processus 1: Envoi de message m sur c1
- Processus 2 : Réception de message m sur c1

Processus 1
(nœud 1)

a

c0

c1!m

Processus 2
(nœud 2)

d

c1?m

y

- Propriétés des canaux
 - Pas de perte de messages
 - FIFO: les messages sont consommés dans l'ordre où ils sont émis

Processus 1
(nœud 1)

a
c0
c1!m


Processus 2
(nœud 2)

d
c1?m
y


- Ordre total des événements pour chaque processus
- Pas d'horloge globale donc pas d'ordre total connu entre les processus
- Ordre sur les messages: une réception d'un message a lieu après son émission

- Deux types de modèles
 - Machine à états:
 - décrire les enchainements possibles d'actions (de manière globale)
 - Invariants:
 - capturer des enchainements d'actions qui restent toujours vrais
- Choix:
 - Les deux !!
 - Pourquoi ... Explication dans la suite...


- Exemple de représentation de l'ordonnancement des événements dans les traces:



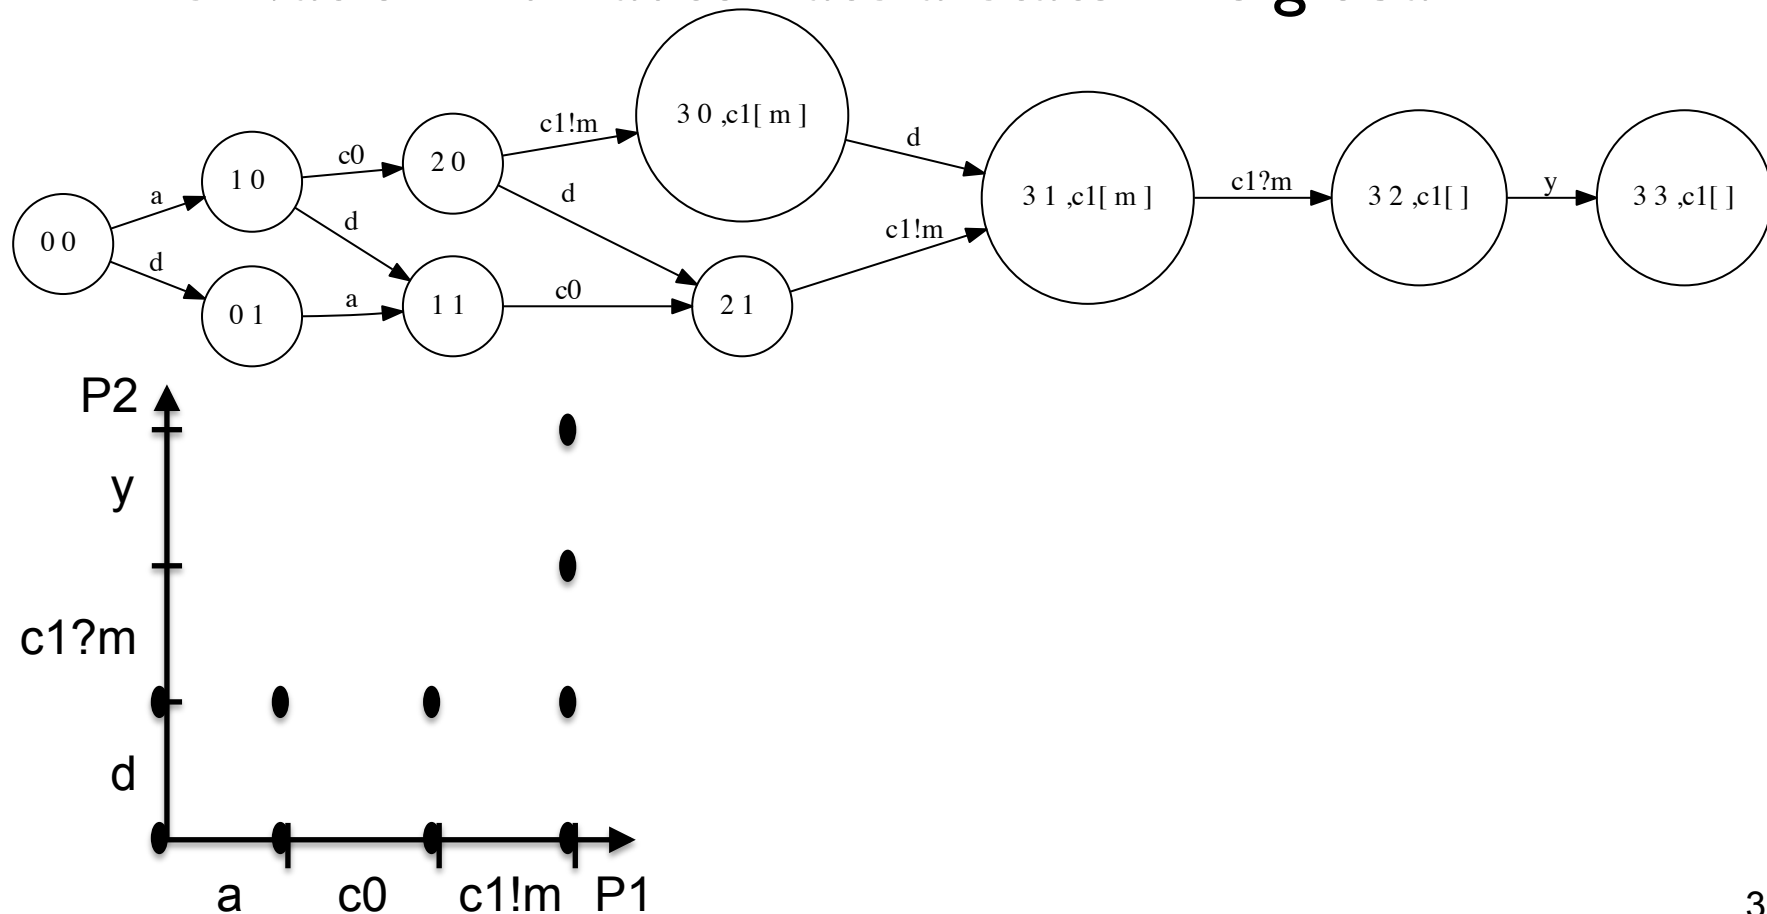
- La réception du message ne peut avoir lieu qu'après son envoi: définition d'un treillis
- Points atteignables dans la représentation:




- Construction de tous les chemins possibles du départ à l'arrivée
- Exemple de chemin



- Dérivation d'un automate à états finis global



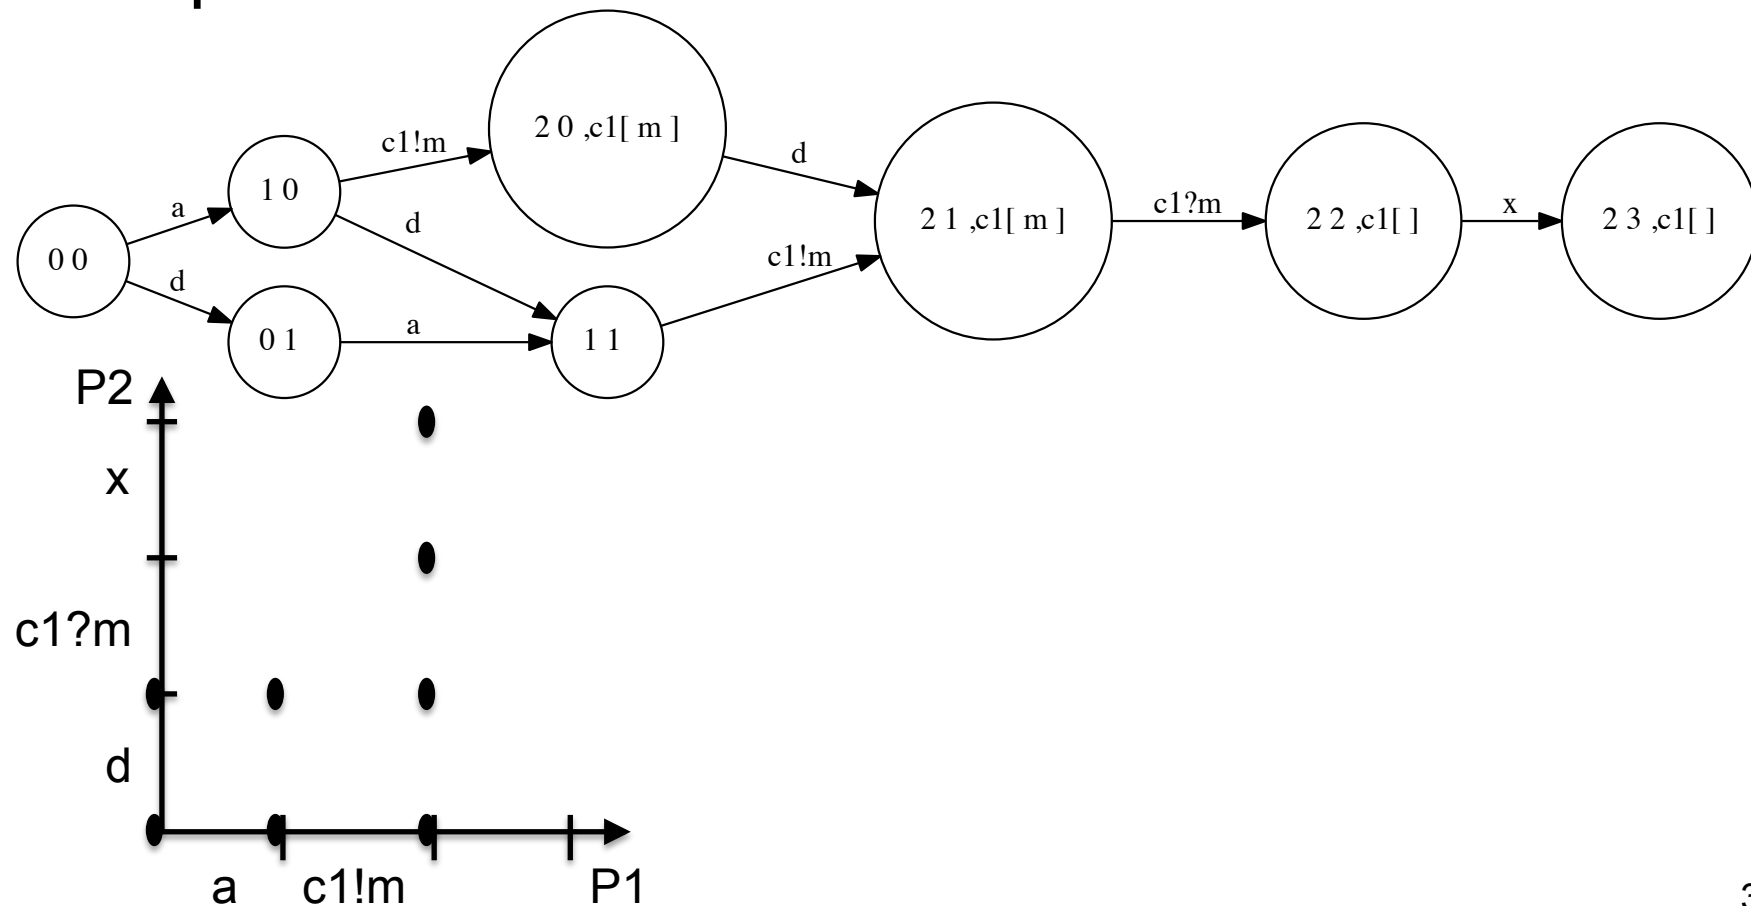
- Dérivation d'un automate à états finis global




- Traces globales possibles

a	a	a	d
c0	c0	d	a
c1!m	d	c0	c0
d	c1!m	c1!m	c1!m
c1?m	c1?m	c1?m	c1?m
y	y	y	y

- Exploitation d'une deuxième trace



- Exploitation d'une deuxième trace




- Traces globales possibles

a	a	d
c1!m	d	a
d	c1!m	c1!m
c1?m	c1?m	c1?m
x	x	x


Construction de l'automate décrivant toutes les traces (PTA)

a	a	a	d	a	a	d
c0	c0	d	a	c1!m	d	a
c1!m	d	c0	c0	d	c1!m	c1!m
d	c1!m	c1!m	c1!m	c1?m	c1?m	c1?m
c1?m	c1?m	c1?m	c1?m	x	x	x
y	y	y	y			



Construction de l'automate décrivant toutes les traces (PTA)

a	a	a	d	a	a	d
c0	c0	d	a	c1!m	d	a
c1!m	d	c0	c0	d	c1!m	c1!m
d	c1!m	c1!m	c1!m	c1?m	c1?m	c1?m
c1?m	c1?m	c1?m	c1?m	x	x	x
y	y	y	y			



Construction de l'automate décrivant toutes les traces (PTA)

a
c0
c1!m
d
c1?m
y

a
c0
d
c1!m
c1?m
y


a
d
c0
c1!m
c1?m
y

d
a
c0
c1!m
c1?m
y



a
c1!m
d
c1?m
x

a
d
c1!m
c1?m
x

d
a
c1!m
c1?m
x




Construction de l'automate décrivant toutes les traces (optimisé)



Automate satisfaisant ?


- L'automate contient potentiellement beaucoup d'états
- Donc besoin de le "compacter"
- Nombreux algorithmes possibles
 - Exemple d'algorithme: k-tail

- Automate initial




- Application de 2-tail: deux états sont 2-équivalents si leur 2-future est le même

- Automate initial



- Application de 2-tail: deux états sont 2-équivalents si leur 2-future est le même


- Automate compacté




- Souci:
 - La séquence e1, e2, e3, e6 est acceptée par l'automate compacté, pas par l'automate initial

- Ces algorithmes sur-généralisent le comportement:
 - Tous les comportements appris sont inclus dans l'automate final
 - L'automate final peut introduire des comportements qui n'appartiennent pas à l'ensemble des comportements observés
- Risque d'introduction de faux négatifs
 - Besoin de conserver les propriétés invariantes vérifiées par l'automate initial

2-tail sur l'exemple (utilisation de k-behaviour)




- Après compactage (ici un seul état de moins)



- Généralement, on considère trois types d'invariants
 - A est toujours suivi de B (A AlwaysFollowedBy B)
 - A n'est jamais suivi de B (A NeverFollowedBy B)
 - A précède toujours B (A AlwaysPrecedes B)
- On va calculer tous les invariants possibles sur le comportement global appris

Utilisation de synoptic pour le calcul des invariants




a AlwaysFollowedBy(t) c1!m
 a AlwaysFollowedBy(t) c1?m
 a AlwaysPrecedes(t) c0
 a AlwaysPrecedes(t) c1!m
 a AlwaysPrecedes(t) c1?m
 a AlwaysPrecedes(t) x
 a AlwaysPrecedes(t) y
 a NeverFollowedBy(t) a

...

c0 AlwaysFollowedBy(t) c1!m
 c0 AlwaysFollowedBy(t) c1?m
c0 AlwaysFollowedBy(t) y
c0 AlwaysPrecedes(t) y
 c0 NeverFollowedBy(t) a
 c0 NeverFollowedBy(t) c0
c0 NeverFollowedBy(t) x


...

- Question: après compactage de l'automate, les invariants sont-ils toujours vérifiés ?
- Réponse apportée par le monde du "model-checking"
 - Étant donné un modèle (automate)
 - Des propriétés (invariants) sont-elles vérifiées par l'automate ?



- Modélisation de l'automate compact:
 - Évolution de variables représentant les états et les transitions
- Modélisation des invariants (LTL: Logique Temporelle Linéaire) de l'automate avant compactage

Modélisation de l'automate: enchaînement des transitions



INIT

trans=INITIAL;

ASSIGN

next(trans):=case

trans = INITIAL : {d,a};

state = 16 & trans = a : {c1_s_m,c0};

state = 12 & trans = c1_s_m : {c1_r_m};


state = 0 & trans = d : {a};

state = 0 & trans = a : {c1_s_m,d,c0};

...

esac;

Modélisation de l'automate: enchainement des états



INIT

state=0;

ASSIGN

next(state):=case

state = 16 & trans = a : {17};

state = 12 & trans = c1_s_m : {8};

state = 0 & trans = d : {16};

state = 0 & trans = a : {1};


state = 8 & trans = c1_r_m : {9};

...

esac;

- Trois types d'invariants à modéliser en LTL
 - A AlwaysFollowedBy B
 - A NeverFollowedBy B
 - A AlwaysPrecedes B
- Sur l'exemple:

```
a AlwaysFollowedBy(t) c1!m -- specification ( F trans = END -> G (trans = a -> F trans = c1_s_m))  
a NeverFollowedBy(t) a      -- specification G (trans = a -> X ( G !( F trans = a)))  
a AlwaysPrecedes(t) c0      -- specification ( F trans = END -> ( F trans = c0 -> (!(trans = c0) U trans = a)))
```



- Résultat du model-checker

c0 AlwaysFollowedBy(t) y is false
 c0 AlwaysPrecedes(t) y is false
 c0 NeverFollowedBy(t) x is false

- Un automate à état fini représentant le fonctionnement global de l'application
- Un ensemble d'invariants permettant d'augmenter la précision de la détection, en éliminant de potentiels faux négatifs
- Compromis à trouver entre le nombre d'états et le nombre d'invariants à vérifier (variation du k de k -tail)
- L'IDS se sert de ces deux modèles pour effectuer la détection